



הסטיקר שילווה אותנו
בתרגיל זה:

1. חלק תאורטי

1.1 EM Initialization

נאתחל $\mu_i^{(0)} = \mu_j^{(0)}, \Sigma_i^{(0)} = \Sigma_j^{(0)}$ $\forall i, j \in [K]$. בנוסף נתונים לנו $\pi_k^{(0)}$ $\forall k$. נטען כי במקרה זה

נקבל כי עבור $t \rightarrow \infty$ הרצות צעדים של EM עבור פתרון ML עבור GMM קבעון על ערכי

$\mu_0, \Sigma_0, \forall k : \pi_k^{(0)}$ עבור כל k , והיותו $\forall k \in [K]$ ערך התחלתי זה זהה, נקבל פתרון $\mu_k^{(t)}, \Sigma_k^{(t)}, \pi_k^{(t)}$

שאתחלנו את האלגוריתם איתו.

נניח נכונות עבור $t \in \mathbb{N}$ ונוכיח עבור $t + 1$. בסיס האינדוקציה הוא כמובן $t = 0$ שנתון לנו. נניח

נכונות עבור $t \in \mathbb{N}$ גדול מספיק ונוכיח. נבחין כי מההנחה נקבל:

$$\forall i : r_{ik_1}^{(t+1)} = \frac{\pi_{k_1}^{(t+1)} \cdot \mathcal{N}(x_i | \mu_{k_1}^{(t)}, \Sigma_{k_1}^{(t)})}{\sum_{k'} \pi_{k'}^{(t+1)} \cdot \mathcal{N}(x_i | \mu_{k'}^{(t)}, \Sigma_{k'}^{(t)})} = \frac{\pi_{k_2}^{(t+1)} \cdot \mathcal{N}(x_i | \mu_{k_2}^{(t)}, \Sigma_{k_2}^{(t)})}{\sum_{k'} \pi_{k'}^{(t+1)} \cdot \mathcal{N}(x_i | \mu_{k'}^{(t)}, \Sigma_{k'}^{(t)})} = r_{ik_2}^{(t+1)}$$

ולכן:

$$\pi_{k_1}^{(t+1)} = \frac{1}{N} \sum_i r_{ik_1}^{(t+1)} = \frac{1}{N} \sum_i r_{ik_2}^{(t+1)} = \pi_{k_2}^{(t+1)}$$

ולכן:

$$\mu_{k_1}^{(t+1)} = \frac{\sum_i r_{ik_1}^{(t+1)} x_i}{\sum_i r_{ik_1}^{(t+1)}} = \frac{\sum_i r_{ik_2}^{(t+1)} x_i}{\sum_i r_{ik_2}^{(t+1)}} = \mu_{k_2}^{(t+1)}$$

$$\begin{aligned}\Sigma_{k_1}^{(t+1)} &= \frac{\sum_i \overbrace{r_{ik_1}^{(t+1)}}^{r_{ik_2}^{(t+1)}} \left(x_i - \mu_{k_1}^{(t+1)} \right) \left(x_i - \overbrace{\mu_{k_1}^{(t+1)}}^{\mu_{k_2}^{(t+1)}} \right)^T}{\sum_i r_{ik_1}^{(t+1)}} = \frac{\sum_i r_{ik_2}^{(t+1)} \left(x_i - \mu_{k_2}^{(t+1)} \right) \left(x_i - \overbrace{\mu_{k_2}^{(t+1)}}^{\mu_{k_2}^{(t+1)}} \right)^T}{\sum_i r_{ik_2}^{(t+1)}} \\ &= \Sigma_{k_2}^{(t+1)}\end{aligned}$$

כעת נקבל זאת עבור כל ערך $t \in \mathbb{N}$ על כן :

$$\forall t \in \mathbb{N}, \forall k : \begin{cases} \mu_0 = \mu_k^{(0)} = \mu_k^{(1)} = \dots = \mu_k^{(t)} \\ \Sigma_0 = \Sigma_k^{(0)} = \Sigma_k^{(1)} = \dots = \Sigma_k^{(t)} \\ \pi_k^{(0)} = \pi_k^{(1)} = \dots = \pi_k^{(t)} \end{cases}$$

: *Gibbs Sampling* .1.2

בהינתן ההתפלגות הבאה :

$$\begin{aligned}p(x, y) &= \frac{1}{Z} \cdot \mathcal{N}(x | \mu_x, \Sigma_x) \cdot \mathcal{N}(y | \mu_y, \Sigma_y) \cdot e^{-\frac{\beta}{2} \|x-y\|^2} \\ &= \frac{1}{Z} e^{-\frac{\beta}{2} \|x-y\|^2} \cdot \underbrace{\mathcal{N}(x | \mu_x, \Sigma_x)}_{e^{-\frac{1}{2}(x-\mu_x)^T \Sigma_x^{-1}(x-\mu_x)}} \cdot \underbrace{\mathcal{N}(y | \mu_y, \Sigma_y)}_{e^{-\frac{1}{2}(y-\mu_y)^T \Sigma_y^{-1}(y-\mu_y)}}\end{aligned}$$

עבור Z קבוע הנרמול ו x, y ווקטורים. נרצה למצוא את ההתפלגות המותנית הרצויה עבור אלגוריתם

gibbs sampling תחת ההתפלגות הנתונה. מדובר על מכפלת גאוסיאנים על כן נקבל גם גאוסיאן.

נרצה לחשב את $p(x|y), p(y|x)$. נתחיל ב $p(x|y)$.

$$p(x, y) = \frac{1}{Z} e^{-\frac{1}{2} \beta I \|x-y\|^2} \exp \left[\underbrace{-\frac{1}{2} (x - \mu_x)^T \Sigma_x^{-1} (x - \mu_x) - \frac{1}{2} (y - \mu_y)^T \Sigma_y^{-1} (y - \mu_y)}_{-\frac{1}{2} (x^T \Sigma_x^{-1} x - 2x^T \Sigma_x^{-1} \mu_x + \mu_x^T \Sigma_x^{-1} \mu_x) - \frac{1}{2} (y^T \Sigma_y^{-1} y - 2y^T \Sigma_y^{-1} \mu_y + \mu_y^T \Sigma_y^{-1} \mu_y)} \right]$$

כעת :

$$\frac{1}{Z} \exp \left(-\frac{1}{2} (x - y)^T \beta I (x - y) \right) = \frac{1}{Z} \exp \left(-\frac{1}{2} (x^T \beta I x - 2x^T \beta I y + y^T \beta I y) \right)$$

לכן :

$$p(x, y)$$

$$= \frac{1}{Z} \cdot \exp \left[\underbrace{-\frac{1}{2}((x^T \Sigma_x^{-1} x - 2x \Sigma_x^{-1} \mu_x + \mu_x^T \Sigma_x^{-1} \mu_x)) - \frac{1}{2}(y^T \Sigma_y^{-1} y - 2y \Sigma_y^{-1} \mu_y + \mu_y^T \Sigma_y^{-1} \mu_y)) - \frac{1}{2}(x^T \beta I x - 2x^T \beta I y + y^T \beta I y)}_{-\Delta} \right]$$

נרצה לגזור על פי x את Δ כמו בטריק הנגזרת בכדי לקבל את $-p(x|y)$

$$\begin{aligned} \frac{\partial(\Delta)}{\partial x} &= \Sigma_x^{-1}(x - \mu_x) + \beta I(x - y) = \Sigma_x^{-1}x + \beta Ix - \Sigma_x^{-1}\mu_x - \beta Iy \\ &= (\Sigma_x^{-1} + \beta I)x - (\Sigma_x^{-1}\mu_x + \beta Iy) \\ &= (\Sigma_x^{-1} + \beta I)^{-1}(x - (\Sigma_x^{-1} + \beta I)^{-1}(\Sigma_x^{-1}\mu_x + \beta Iy)) \end{aligned}$$

ונקבל:

$$p(x|y) \sim \mathcal{N}((\Sigma_x^{-1} + \beta I)^{-1}(\Sigma_x^{-1}\mu_x + \beta Iy), (\Sigma_x^{-1} + \beta I)^{-1})$$

נרצה לגזור על פי y את Δ כמו בטריק הנגזרת בכדי לקבל את $-p(y|x)$

$$\begin{aligned} \frac{\partial \Delta}{\partial y} &= \Sigma_y^{-1}(y - \mu_y) + \beta I(y - x) = \Sigma_y^{-1}y + \beta Iy - \Sigma_y^{-1}\mu_y - \beta Ix \\ &= (\Sigma_y^{-1} + \beta I)y - (\Sigma_y^{-1}\mu_y + \beta Ix) \\ &= (\Sigma_y^{-1} + \beta I)^{-1}(y - (\Sigma_y^{-1} + \beta I)^{-1}(\Sigma_y^{-1}\mu_y + \beta Ix)) \end{aligned}$$

ולכן:

$$p(y|x) \sim \mathcal{N}((\Sigma_y^{-1} + \beta I)^{-1}(\Sigma_y^{-1}\mu_y + \beta Ix), (\Sigma_y^{-1} + \beta I)^{-1})$$

2. חלק פרקטי